

Porównanie zaawansowanych metod klasyfikacji i analizy skupień

Katarzyna Bednarkiewicz, Ewelina Dąbrowa

2026-07-17

Spis treści

1	Zaawansowane metody klasyfikacji	1
1.1	Rodziny klasyfikatorów/uczenie zespołowe (ang. ensemble learning).	1
1.2	Metoda wektorów nośnych (SVM)	2
1.3	Porównanie skuteczności metod	5
2	Analiza skupień – algorytmy grupujące i hierarchiczne.	7
2.1	Wybór i przygotowanie danych.	7
2.2	Wizualizacja wyników grupowania.	7
2.3	Ocena jakości grupowania. Wybór optymalnej liczby skupień i porównanie metod.	10
2.4	Interpretacja wyników grupowania – charakterystyki skupień.	13
2.5	Analiza zgodności klastrow PAM z rzeczywistymi klasami szkła	14
2.6	Końcowe wnioski	16

1 Zaawansowane metody klasyfikacji

1.1 Rodziny klasyfikatorów/uczenie zespołowe (ang. ensemble learning).

Zajmiemy się analizą zaawansowanych metod klasyfikacji na podstawie danych *Glass*. Rozpatrzmy dwa z algorytmów typu ensemble learning, tj. bagging oraz boosting w konstrukcji reguł klasyfikacyjnych oraz zbadamy ich dokładność w porównaniu z dokładnością klasyfikacji dla pojedynczego drzewa. Wczytujemy i dołączamy dane *Glass* z pakietu *mlbench*.

Budujemy pojedyncze drzewo klasyfikacyjne.

Skonstruujemy teraz reguły klasyfikacyjne na bazie w.w. algorytmów i porównamy ich dokładność. Dla każdego z algorytmów przyjmujemy domyślnie liczbę replikacji wynoszącą 25.

	Błąd klasyfikacyjny	Względna redukcja błędu (w %)
Pojedyncze drzewo	0.320	0.000
Bagging	0.190	40.790
Boosting	0.187	41.532

Tabela 1: Tabela zawierająca błędy klasyfikacyjne dla różnych algorytmów klasyfikacji oraz wyrażoną w procentach względną redukcję błędu danego algorytmu względem pojedynczego drzewa

Wyniki przedstawione w Tabeli 1 sugerują, że w przypadku obu badanych algorytmów otrzymujemy istotną redukcję błędu klasyfikacyjnego względem klasyfikatora bazowego. Dla bagging błęd wynosi 0.19, a jego względna redukcja jest na poziomie 40.79%. Dla boostingu otrzymujemy błąd równy 0.187, a jego względna redukcja błędu wynosi 41.532%. Możemy zaobserwować, że występują różnice w dokładności klasyfikacji pomiędzy baggingiem a boostingiem, mianowicie boosting wykazał się większą dokładnością klasyfikacji, jednak nie są one istotnie duże. Prawdopodobnie dobierając bardziej optymalne parametry dla obu algorytmów, moglibyśmy zaobserwować wzrost owej różnicy.


1.2 Metoda wektorów nośnych (SVM)

Wykorzystując algorytm SVM, budujemy klasyfikatory dla różnych funkcji jądrowych (jądro liniowe, wielomianowe i radialne). Zbadamy, jak wybór parametru kosztu C wpływa na dokładność klasyfikacji dla jądra liniowego.

C	Dokładność
0.10	0.61
1.00	0.69
10.00	0.64

Tabela 2: Porównanie wpływu parametru C

W Tabeli 2 widzimy, że najwyższą skuteczność dla modelu z liniową funkcją jądrową osiągamy dla parametru $C = 1.00$ (dokładność 0.69). Zbyt niska ($C = 0.10$) i zbyt wysoka ($C = 10.00$) wartość tego parametru prowadzi do pogorszenia wyników klasyfikacji.



Rysunek 1: Wpływ parametru C na błąd klasyfikacji dla jądra liniowego

Na Rysunku 1 widzimy, że dla niskich wartości C model z wykorzystaniem liniowej funkcji jądrowej daje najwyższy błąd, następnie następuje gwałtowny spadek. W przedziale wartości C od 1 do 4 błąd stabilizuje się na dość stabilnym poziomie (ok. 0.37), zaś minimum osiąga dla parametru $C = 8$ (błąd ok. 0.35). Dalsze zwiększanie kosztu (powyżej 10) skutkuje ponownym, nieznacznym wzrostem błędu, co sugeruje początek zjawiska przetrenowania (overfittingu).


Teraz porównamy wpływ wyboru funkcji jądrowej na skuteczność metody.

Jądro	Dokładność
Liniowe ($C=10$)	0.64
Wielomianowe ($C=1$, $d=2$)	0.65
Wielomianowe ($C=1$, $d=4$)	0.50
Radialne ($C=1$)	0.76
Radialne ($C=1$, $\gamma=0.1$)	0.75
Radialne ($C=1$, $\gamma=1$)	0.72

Tabela 3: Porównanie funkcji jądrowych SVM

Na podstawie wyników przedstawionych w Tabeli 3 widzimy, że najwyższą skuteczność osiągamy dla jądra radialnego z domyślnymi parametrami, gdzie dokładność wynosi 0.76. Jądro liniowe ($C = 10$) oraz wielomianowe drugiego stopnia ($d = 2$) charakteryzują się gorszą dokładnością (odpowiednio 0.64 i 0.65). Najniższe wyniki osiąga jądro wielomianowe, przy czym zwiększenie stopnia wielomianu z $d = 2$ do $d = 4$ jeszcze bardziej zmniejszyło dokładność klasyfikacji - aż do poziomu 0.50.

Teraz dla jądra radialnego spróbujemy dobrać optymalne parametry γ i C .



Rysunek 2: Wpływ parametru gamma oraz C na błąd klasyfikacji

Na Rysunku 2 widzimy jak dobór parametrów C oraz gamma wpływa na błąd klasyfikacji. Dla niskich wartości C błąd jest bardzo duży, jego zwiększanie zdecydowanie zmniejsza błąd klasyfikacji, o ile dobór parametru gamma będzie optymalny. Zbyt wysokie (ponad 2 w skali log) lub zbyt niskie gamma powodują, że błąd będzie wysoki. Najlepszą skuteczność modelu osiągamy zatem dla wartości C z przedziału od około 1 do 3 (w skali log) (ok. 3 do 20 w skali rzeczywistej), a γ w okolicach od -3 do -1 (w skali log) (od ok. 0.05 do 0.37 w skali rzeczywistej).

W wyniku strojenia wyznaczyliśmy optymalne wartości parametrów: $C=8$, $\gamma=0.5$. Model z

“dostrojonymi” parametrami osiągnął skuteczność 0.694, podczas gdy z domyślnymi parametrami dawał skuteczność równą 0.764. Optymalizacja parametrów sprawiła, że dokładność klasyfikacji spadła, lecz uzyskaliśmy model o lepszych właściwościach generalizujących i mniejszej podatności na overfitting.

1.3 Porównanie skuteczności metod

Metoda	Typ jądra	Dobre parametry	Dokładność (Trening)	Dokładność (Test)
Random Forest	-	ntree = 500	1.000	0.778
Bagging	-	nbagg = 25	0.986	0.986
Boosting	-	mfinal = 25	0.958	0.694
SVM	Liniowe	$C = 10$	0.754	0.639
SVM	Wielomianowe	$d = 4$	0.606	0.500
SVM	Radialne	$\gamma = 0.1, C = 1.00$	0.732	0.750
SVM	Radialne	$\gamma = 0.5, C = 8$	0.965	0.694

Tabela 4: Tabela porównująca dokładność klasyfikacji dla różnych algorytmów na zbiorze treningowym oraz testowym

Tabela nr 4 prezentuje porównanie dokładności dla rozważanych algorytmów na zbiorze treningowym oraz testowym. Uwzględniliśmy w niej różne wartości parametrów, w celu ustalenia, która z rozważanych metod wykazała się najlepszą skutecznością. Wynika z niej, że zdecydowanie najwyższą dokładnością na zbiorze testowym charakteryzuje się metoda Bagging, która osiągnęła wynik 0.986, wykazując przy tym doskonałą stabilność i brak tendencji do przeuczenia (dokładność na zbiorze treningowym również wyniosła 0.986). Drugim pod względem skuteczności algorytmem okazał się Random Forest z dokładnością testową na poziomie 0.778, choć w jego przypadku widoczne jest pełne dopasowanie do danych treningowych (1.000). Algorytm Boosting uzyskał na zbiorze testowym słabszy wynik (0.694). W przypadku algorytmu SVM skuteczność była silnie uzależniona od doboru jądra oraz parametrów. Najlepsze wyniki w tej grupie uzyskało jądro radialne przy parametrach $\gamma = 0.1$ oraz $C = 1.00$, osiągając dokładność testową równą 0.750 (co ciekawe, wyższą niż na zbiorze treningowym: 0.732). Zwiększenie parametrów dla jądra radialnego ($\gamma = 0.5, C = 8$) doprowadziło do przeuczenia modelu - mimo bardzo wysokiej dokładności treningowej (0.965), skuteczność testowa spadła do 0.694. Pozostałe warianty SVM poradziły sobie wyraźnie słabiej: jądro liniowe ($C = 10$) uzyskało wynik testowy 0.639, a najniższą skutecznością spośród wszystkich badanych metod wykazało się jądro wielomianowe ($d = 4$), osiągając wynik zaledwie 0.500.

	1	2	3	5	6	7
1	20	6	2	0	0	0
2	2	19	1	2	0	1
3	0	0	1	0	0	0
5	0	1	0	1	0	1
6	0	0	0	0	2	0
7	1	1	0	0	0	11

Tabela 5: Macierz pomyłek dla Random Forest

W Tabeli 5 przedstawiono macierz pomyłek dla Random Forest na zbiorze testowym. Model Random Forest osiągnął dokładność klasyfikacji równą 0.778.

	1	2	3	5	6	7
1	16	6	1	0	0	0
2	3	16	1	0	0	1
3	3	1	2	0	0	0
5	0	3	0	3	0	1
6	0	0	0	0	2	0
7	1	1	0	0	0	11

Tabela 6: Macierz pomyłek dla Boosting

W Tabeli 6 przedstawiono macierz pomyłek dla metody boosting na zbiorze testowym. Model osiągnął dokładność klasyfikacji równą 0.694.

	1	2	3	5	6	7
1	23	0	0	0	0	0
2	0	26	0	0	0	0
3	0	0	4	0	0	0
5	0	1	0	3	0	0
6	0	0	0	0	2	0
7	0	0	0	0	0	13

Tabela 7: Macierz pomyłek dla Bagging

W Tabeli 7 przedstawiono macierz pomyłek dla metody bagging na zbiorze testowym. Model osiągnął dokładność klasyfikacji równą 0.986.

Na podstawie przedstawionych macierzy pomyłek można zauważyć, że najlepsze wyniki osiągnął model oparty na metodzie bagging. Spoglądając na macierz pomyłek, model ten niemal bezbłędnie sklasyfikował próbki ze wszystkich klas. Algorytm Random Forest (dokładność 0.75) poradził sobie wyraźnie lepiej niż klasyczny Boosting (dokładność 0.625). Dla Random Forest i Boosting największe trudności sprawiło poprawne rozróżnienie klasy 1 oraz klasy 2 - często dochodziło między nimi do wzajemnych pomyłek. Model Boosting miał ogromny

problem z klasą 3 - żadna z próbek nie została sklasyfikowana poprawnie. Obie metody (Random Forest i Boosting) stosunkowo dobrze poradziły sobie z rozpoznawaniem klasy 7.


2 Analiza skupień – algorytmy grupujące i hierarchiczne.

2.1 Wybór i przygotowanie danych.

Do analizy ponownie wybieramy dane *Glass*, które pochodzą z pakietu *mlbench*. Zbiór tych danych zawiera informacje o składzie chemicznym różnych rodzajów szkła. Dane te zostały uzyskane na podstawie kryminalistycznych badań powypadkowych. Został on udostępniony przez Friedricha Leischa pod koniec lat 90. XX wieku. Losujemy podzbiór zawierający 200 rekordów oraz usuwamy zmienną grupującą *Type*. W przypadku tych danych przed wyznaczeniem macierzy odległości/odmienności konieczne będzie zastosowanie standaryzacji.

2.2 Wizualizacja wyników grupowania.


Przeprowadzamy podział na skupienia algorytmem k-średnich (k-means), przyjmując liczbę skupień K równą rzeczywistej liczbie klas występujących w danych, co pozwala porównać uzyskany podział z rzeczywistą strukturą klas.



Rysunek 3: Podział na skupiska metodą k-means


Na Rysunku 3 przedstawiono podział obiektów na skupiska uzyskany za pomocą algorytmu k-means. Do wizualizacji wykorzystujemy metodę PCA. Możemy zauważyć, że skupisko dla 6 klastra jest wyraźnie odseparowane od reszty. Skupisko 4, pomimo częściowego nakładania się z klastrem 2, również jest dość dobrze oddzielone. Klaster nr 3 zaś na wykresie tworzy odstającą od reszty kropkę po lewej stronie. Skupisko 5 częściowo pokrywa się z klastrem 1. Pozostałe skupiska (1, 2) natomiast dość mocno nakładają się na siebie.

Teraz przyjrzyjmy się dendrogramom dla analizowanych podejść hierarchicznych.




Rysunek 4: Dendrogram dla metody Average linkage

Na Rysunku 4 widzimy dendrogram dla metody Average linkage. Drzewo grupuje obiekty ze zbioru danych na skupiska, lecz wydziela kilka odseparowanych pojedynczych gałęzi. Po prawej stronie wykresu są widoczne obserwacje odstające.



Rysunek 5: Dendrogram dla metody Single linkage

Na Rysunku 5 widzimy dendrogram dla metody Single linkage. Metoda ta słabo radzi sobie z wydzieleniem odseparowanych skupień i wyraźnie widoczne są pojedyncze obserwacje odstające. Dendrogram powstały dla tej metody jest najniższy.



Rysunek 6: Dendrogram dla metody Complete linkage


Na Rysunku 6 przedstawiono dendrogram dla metody Complete linkage. Ta metoda tworzy najwyraźniejsze, zwarte odeparowane grupy, jednak po prawej stronie wykresu nadal widzimy obserwacje odstające. Dendrogram dla tej metody jest najwyższy w porównaniu do innych analizowanych podejść.

2.3 Ocena jakości grupowania. Wybór optymalnej liczby skupień i porównanie metod.

K	pam	agnes
2	0.415	0.666
3	0.244	0.641
4	0.274	0.545
5	0.290	0.495
6	0.318	0.452

Tabela 8: Średnie wartości indeksu Silhouette dla różnej ilości skupisk dla algorytmów Pam i Agnes

Średnia wartość indeksu Silhouette dla różnej liczby skupień




Rysunek 7: Wykres przedstawiający średnią wartość indeksu Silhouette dla algorytmów Pam i Agnes dla różnej liczby skupisk

Tabela 8 oraz Rysunek 7 przedstawiają średnią wartość indeksu Silhouette dla różnej ilości skupisk dla algorytmów Pam i Agnes. Wynika z nich, że lepszym podziałem na klastry pod względem zwartości i ich separacji przestrzennej charakteryzuje się algorytm Agnes (wyższe wartości wskaźnika). Dla Pam możemy zauważyć, że od $K = 3$ wartości wskaźnika zaczynają rosnąć, podczas gdy dla Agnes wartości wraz ze wzrostem liczby skupisk maleją. Najwyższą wartość wynoszącą 0.666 wskaźnik osiąga dla $K = 2$ dla algorytmu Agnes.

metoda	K	zgodność
PAM	2	0.465
AGNES	2	0.365
PAM	3	0.480
AGNES	3	0.365
PAM	4	0.470
AGNES	4	0.370
PAM	5	0.530
AGNES	5	0.370
PAM	6	0.540
AGNES	6	0.385

Tabela 9: Wskaźniki zewnętrzne dla różnej ilości skupisk dla algorytmów Pam i Agnes

Wartość wskaźnika zewnętrznego dla różnej liczby skupień



Rysunek 8: Wykres przedstawiający wartość wskaźnika zewnętrznego dla algorytmów Pam i Agnes dla różnej liczby klastrów

Tabela 9 oraz Rysunek 8 prezentują wartości wskaźnika zgodności przyporządkowania obiektów do odpowiednich klastrów dla algorytmów Pam i Agnes dla różnej liczby skupisk. Mo-

żemy z nich wywnioskować, że na ogół z przyporządkowywaniem lepiej radzi sobie algorytm Pam. Dla dowolnej liczby skupisk cechuje się on znacznie wyższą wartością tego wskaźnika niż algorytm Agnes. Dla Agnes wartości wskaźnika nieznacznie rosną wraz ze wzrostem liczby klastrów, zaś dla Pam odnotowujemy znacznie bardziej zauważalny wzrost, który osiąga kulminacyjną wartość 0.54 dla liczby skupisk $K = 6$

Na podstawie otrzymanych wyników dla wskaźnika Silhouette oraz wskaźnika zgodności jest wręcz niemożliwe, aby zdecydować, który algorytm poradził sobie lepiej. Według wskaźnika Silhouette lepiej poradził sobie algorytm Agnes, ale dla wskaźnika zgodności jest przeciwnie. W związku z tym nie można jednoznacznie wskazać lepszej metody wyłącznie na podstawie tych dwóch miar. Aby dokonać bardziej wiarygodnej oceny, należałoby uwzględnić większą liczbę wskaźników jakości grupowania.

2.4 Interpretacja wyników grupowania – charakterystyki skupień.

W celu interpretacji powstałych klastrów, przeanalizujemy profile skupień uzyskane za pomocą algorytmu PAM dla rzeczywistej liczby skupień ($K = 6$). Poniższa tabela przedstawia średnie wartości poszczególnych składników chemicznych w wyodrębnionych skupiskach, co pozwala scharakteryzować specyfikę każdego z nich.


skupisko	RI	Na	Mg	Al	Si	K	Ca	Ba	Fe
1	1.517	14.669	0.382	2.176	72.965	0.212	8.324	1.195	0.012
2	1.517	13.232	3.320	1.409	72.822	0.570	8.436	0.015	0.012
3	1.518	13.071	3.316	1.339	72.743	0.534	8.719	0.027	0.225
4	1.524	12.855	0.354	1.391	72.347	0.270	12.426	0.166	0.064
5	1.522	13.867	3.602	0.872	71.665	0.154	9.703	0.034	0.026
6	1.513	13.010	0.000	3.030	70.590	6.210	6.945	0.000	0.000

Tabela 10: Średnie rzeczywiste wartości składników chemicznych szkła w poszczególnych skupiskach dla algorytmu PAM ($K=6$)

Tabela 10 przedstawia profile chemiczne skupień uzyskanych metodą PAM dla $K = 6$. Przedstawione wartości odpowiadają rzeczywistym średnim zawartościom składników chemicznych szkła, co pozwala na łatwiejszą interpretację charakterystyki poszczególnych grup.

Największe różnice pomiędzy skupieniami obserwowane są dla zawartości Na, Mg, Al oraz Ca. Szczególnie interesujące są skupiska 4 i 6, które wyróżniają się odmiennym składem chemicznym. Skupisko 4 charakteryzuje się wysoką zawartością wapnia oraz podwyższonym współczynnikiem załamania światła, natomiast skupisko 6 podwyższonym poziomem potasu i glinu. Pozostałe skupiska wykazują bardziej zbliżone profile chemiczne, co wskazuje na częściowe nakładanie się grup w przestrzeni cech.

2.5 Analiza zgodności klastrów PAM z rzeczywistymi klasami szkła




Rysunek 9: Porównanie klas rzeczywistych i klastrów

Na Rysunku 9 przedstawiono mapę ciepła obrazującą zgodność pomiędzy rzeczywistymi klasami szkła a klastrami uzyskanymi metodą PAM. Widoczna jest wysoka zgodność dla klasy 7, która została w większości przyporządkowana do jednego klastra. Może to wskazywać, że obiekty tej klasy charakteryzują się profilem chemicznym bardziej odmiennym od pozostałych grup. Jednocześnie można zauważyć częściowe nakładanie się klas 1 i 2, które zostały przypisane do tych samych klastrów. Sugeruje to, że obiekty reprezentujące te typy szkła charakteryzują się podobnymi profilami chemicznymi i są trudniejsze do rozdzielania. Pozostałe klastry odpowiadają bardziej specyficznym grupom obiektów, jednak ich mniejsza liczebność oraz częściowe mieszanie się z innymi klasami wskazują, że nie tworzą one wyraźnie separowalnych struktur w przestrzeni analizowanych cech.

Wartość Adjusted Rand Index wyniosła 0.162, co wskazuje na słabą zgodność pomiędzy klastrami PAM a rzeczywistymi klasami szkła. Wynik ten sugeruje, że rzeczywiste klasy w

zbiornice Glass nie tworzą idealnie odseparowanych grup, część typów szkła może mieć bardzo podobny skład chemiczny.




Rysunek 10: Mapa ciepła średnich wartości składników chemicznych w klastrach PAM

Na Rysunku 10 przedstawiono mapę ciepła średnich, standaryzowanych wartości składników chemicznych dla klastrow uzyskanych metodą PAM. Zastosowanie standaryzacji pozwala na bezpośrednie porównanie względnych różnic między cechami. Wizualizacja ta w czytelny sposób odzwierciedla unikalne profile chemiczne poszczególnych skupień:

- **Klaster 1:** podwyższona zawartość sodu *Na* oraz baru *Ba*.
- **Klaster 3:** podwyższone stężenie żelaza *Fe*.
- **Klaster 4:** podwyższony poziom wapnia *Ca* oraz współczynnika załamania światła.
- **Klaster 6:** podwyższona zawartość glinu *Al* i potasu *K*.

Z kolei klastry 2 i 5 posiadają najbardziej zbliżone profile, bez wyraźnej dominacji żadnego ze składników, co może tłumaczyć częściowe nakładanie się klas rzeczywistych w przestrzeni cech.



Rysunek 11: Wizualizacja PCA klas rzeczywistych

Wizualizacja PCA przedstawiona na Rysunku 11 pokazuje, że część klas szkła posiada wyraźne odseparowane obszary (np. 7), jednak wiele grup wykazuje znaczne nakładanie się. Wyjaśnia to ograniczoną wartość ARI uzyskaną dla algorytmu PAM, ponieważ podobne profile chemiczne utrudniają jednoznaczne rozdzielenie klas.

2.6 Końcowe wnioski

Metoda	ARI	silhouette
K-means	0.165	0.316
PAM	0.162	0.318
AGNES	0.019	0.452

Tabela 11: Porównanie

Uzyskane wyniki przedstawione w Tabeli 11 pokazują, że dane Glass nie tworzą naturalnie separowalnych grup odpowiadających wszystkim rzeczywistym klasom szkła. Analiza wykazała, że struktura chemiczna danych Glass częściowo pokrywa się z rzeczywistymi klasami szkła, jednak nie pozwala na ich pełne odtworzenie metodami nienadzorowanymi. Najlepszą zgodność z rzeczywistymi etykietami uzyskał algorytm k-means ($ARI=0.165$), natomiast metoda AGNES oraz PAM osiągały wyższe wartości wskaźników oceny wewnętrznej, wskazując na lepszą zwartość i separację uzyskanych skupień. Otrzymane wyniki pokazują również, że wysoka jakość wewnętrzna klastrów nie musi oznaczać zgodności z rzeczywistą klasyfikacją. Algorytmy grupowania identyfikują podobieństwo chemiczne, które może jednak różnić się od klasyfikacji stworzonej na podstawie zastosowania szkła.